EDA - EXPLORATORY DATA ANALYSIS



Proyecto módulo Data Analysis

En este proyecto vas a aplicar todo lo aprendido en el Fundamentals y el módulo de Data Analysis del bootcamp. Tendrás que realizar un análisis exploratorio de datos y presentar los resultados. Ten en cuenta lo siguiente:

- **Miembros**: El proyecto es individual
- **Datos**: Tienes que conseguir los datos por tu cuenta (ver abajo)
- **Fecha límite**: Lunes 2 de Noviembre.
- **Entrega**: Deberá subirse un enlace al repositorio de GitHub del proyecto.

Objetivo

Lo que queremos mediante este tipo de análisis es resolver un problema real apoyándonos en datos, por lo que tendrás que plantearte primero qué es lo que quieres resolver, y a partir de ahí identificar fuentes de datos e ir trabajando con ellos para acabar llegando a una conclusión.

Plantea tus hipótesis antes de realizar el análisis exploratorio y después verifica si se han cumplido, o si has descubierto mediante los datos que lo que ocurría era justamente lo opuesto a lo que pensabas.

Evaluación

- **Presentación**: máximo 10 minutos donde expondrás tu caso (ver apartado Presentación).
- **Memoria**: un jupyter notebook donde explicarás el desarrollo del proyecto con markdown y código de python. (Introducción, Fuentes de datos, Limpiezas, Desarrollo análisis, Medidas estadísticas, Visualizaciones, Conclusiones,etc.).
- **Código**: hay que entregar todo el código desarrollado. También se tiene en cuenta (tipo solución, documentación...)
- **Subir el proyecto a tu GitHub personal**: Este gran esfuerzo tiene que ser compartido, crea un repositorio en GitHub para ir añadiendo tus proyectos personales. En caso de que el proyecto se componga de datos sensibles o no

se quiera publicar, se puede mantener en repositorio privado (consultar profesores).

Entregable

El enlace al repositorio de github que habrá que subir a Campus Virtual. Debe constar:

- Presentación
- Memoria
- Código

El codigo deberá seguir la siguiente estructura de carpetas:

1. src/: aquí irá todo el código
2. src/data: todos los archivos de datos utilizados en el analisis. No subir a GitHub archivos demasiado pesados.
3. src/notebooks: los notebooks usados para pruebas.
4. src/utils: todos los modulos, funciones auxiliares o clases creados para el desarrollo del proyecto.
5. src/memoria.ipynb: en este notebook tendrás que resumir de forma clara y ordenada todos los pasos de la analítica.

GitHub: hay que crear un README con una descripción de tu proyecto. Breve. El objetivo de este README es enterarse de forma rápida de qué va tu proyecto y qué tecnologías has utilizado para llevarlo a cabo, no es más que un escaparate de tu trabajo. Hay que ir documentando bien los trabajos para acabar el bootcamp con un buen portfolio. En este enlace tienes un ejemplo de cómo tener documentados los proyectos en tu GitHub.

Presentación

Puesto que en la vida real la mayoría de presentaciones se realizan a un público no técnico, ésta no va a ser menos. Si tienes que explicar algo técnico, cuéntalo, pero para alguien que no sabe lo que significa.

Por ejemplo, ¿cómo explicarías qué es una matriz de correlación? **No queremos ver código**, ni cómo estructuraste el proyecto en carpetas, ni cómo de difícil ha sido limpiarlo. Al cliente o a tu jefe eso le importa poco :) Explicar cosas técnicas lleva tiempo por lo que piensa muy bien en lo que vas a decir y en cómo lo sintetizarás.

Tendrás que exponer bien tu caso de uso con su contexto, explicar qué transformaciones y línea de análisis has abordado, y acabar la presentación con unas

conclusiones y oportunidades que nos brinda el proyecto, para cerrar el plantemiento inicial del caso de uso.

¿Formatos de la presentación? Nada de Notebooks. Formato presentación en PowerPoint, Google Slides, Prezi o la plataforma que mejor conozcas, siendo perfectamente combinable con un dashboard.

Consejos de Presentación

- Si usas un PowerPoint, este será solo tu apoyo a la hora de presentar, porque aquí el protagonista es tu **discurso**.
- Intenta que la presentación no sea un conjunto de puntos inconexos, sino que tenga un hilo narrativo, como si de una historia se tratase.
- "Véndete", es decir destaca las fortalezas de tu trabajo sobre sus debilidades, y si es posible intenta interactúar con el público.
- Si vas a contar algo de negocio, ¿puedes traducirlo a números? ¿Qué impacto tendrá tu analítica? Muestra algunos datos concretos (estadísticos simples) para justificar tu *business case* o para cerrar tu presentación.
- Si has elegido una temática que está acorde con tus gustos o *background*, aprovecha al principio para contarlo y empatizar mucho más con el público.
- Si tu proyecto requiere una demo, haz siempre una grabación de seguridad por si hay problemas técnicos en la presentación (no hay conexión a Internet, etc.).
- Adelantate, prepara las respuestas a algunas posibles preguntas en un anexo de la presentación.

NOTA: existen muchas plantillas gratuitas en la web para hacer presentaciones. Aquí tienes unas cuantas.

Pasos del proyecto

1. Elegir temática
    1. **Elegir una temática y buscar datos en función de la misma**. Puede ocurrir que no encuentres datos que te sirvan para tu propósito, o que tengas que conseguirlos mediante APIs, scraping, descarga de BBDD, etc. No obstante, esta opción es la que más se asemejaría a un caso real, ya que una gran problemática en este tipo de proyectos es encontrar datos.
    2. **Directamente ir a páginas de datos abiertos y escoger un dataset de tu interés**. Si no tienes clara la temática puedes buscar en alguno de los enlaces de datos (recomendable Kaggle) y escoger un tema que te motive.

2. Obtención de datos. ¿Puedes llevar a cabo el proyecto con estos datos?
3. Define tu hipótesis. ¿Qué piensas que puedes analizar de estos datos? ¿Qué vas a poder resolver? ¿Cómo lo vas a llevar a cabo?
4. Preprocesado: obtén todos los datos de las diferentes fuentes que hayas utilizado, juntalos y ponlos en un formato entendible.
5. Limpia los datos: transformaciones, duplicados, missings, columnas inútiles...
6. Exploratorio: obtén todos los estadísticos y gráficos que necesites para entender bien tu dataset y apoyar tus argumentos.
7. Concluye con tu análisis si estabas o no en lo cierto acerca de tu planteamiento y tu hipótesis.
8. Crea una presentación con un hilo conductor sobre tu análisis exploratorio
9. Documenta tu proyecto y súbelo a GitHub.
10. OPCIONAL: Si sabes cómo hacerlo, y te sobra tiempo, crea un dashboard para representar tu análisis exploratorio.

Datos

¿De dónde saco los datos? Posibles fuentes:

- Web de datos abiertos del gobierno
- OpenStreetMap
- Obtención de datos bursátiles
- ESRI Datos abiertos España
- INE
- Red.es
- Datos abiertos gobierno
- Ayuntamiento de Barcelona
- Metro de Madrid
- Portal datos europeo I
- Portal datos europeo II
- Google Dataset Search
- Indicadores macro mundiales I
- Indicadores macro mundiales II
- Amplio repositorio de Datasets

- Datos macro mundiales
- GitHub con gran cantidad de APIs públicas
- Web de datos abiertos de España
- Redapi: Plataforma de APIs con amplia capa gratuita
- Artículo para trabajar con histórico de bolsa
- API de Idealista
- API de Booking
- API de Tripadvisor
- API de Facebook
- API de Twitter
- API de Instagram
- APIs de Google Maps
- Google Timeline
- Alexa. Tráfico de webs
- Catastro
- Airbnb

Otras Herramientas

- Web scraping. Acceso automatizado a cualquier web.
- Kaggle: página con competiciones de data scientists. Muchísimos datasets.
- QPython 3L: APP para ejecutar código Python en el movil. Podrás sacar datos de tu actividad con el teléfono (horarios, geoposicionamiento)

Si tienes algún tema sobre el que quieras investigar, y no encaja con ninguno de los enlaces propuestos, consúltalo con los profesores para investigar de dónde podríamos sacar datos para ese análisis.